



Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«Московский государственный технический университет
имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ _____ «Информатика и системы управления»

КАФЕДРА _____ «Теоретическая информатика и компьютерные технологии»

Домашняя работа №2
по курсу «Теория искусственных нейронных сетей»
«Разработка многослойного персептрона»

Студент группы ИУ9-71Б Окутин Д. А.

Преподаватель Каганов Ю. Т.

Москва 2024

1 Цель

Цель данной лабораторной работы: Изучение многослойного персептрона, исследование его работы на основе использования различных методов оптимизации и целевых функций.

2 Задание

1. Реализовать на языке высокого уровня многослойный персептрон и проверить его работоспособность на примере данных, выбранных из MNIST dataset.
2. Исследовать работу персептрона на основе использования различных целевых функций. (среднеквадратичная ошибка, перекрестная энтропия, дивергенция Кульбака-Лейблера).
3. Исследовать работу многослойного персептрона с использованием различных методов оптимизации (градиентный, Флетчера-Ривза (FR)).
4. Провести исследование эффективности работы многослойного персептрона при изменении гиперпараметров (количества нейронов и количества слоев).
5. Подготовить отчет с распечаткой текста программы, графиками результатов исследования и анализом результатов.

3 Реализация

Исходный код представлен в листинге 1 - 5.

Листинг 1: Импорт используемых библиотек и скачивание датасета MNIST

```
1
2 from torchvision.datasets import MNIST
3 from torch.utils.data import DataLoader
4 from matplotlib import pyplot as plt
5 import numpy as np
6 from IPython.display import clear_output
7 import sys
8
9 transform = lambda img: np.array(np.asarray(img).flatten())/256
10 train_dataset = MNIST('.', train=True, download=True, transform=
    transform)
```

```

11 test_dataset = MNIST( '.', train=False, transform=transform)
12
13 train_loader = DataLoader(train_dataset, batch_size=32, shuffle=True)
14 test_loader = DataLoader(test_dataset, batch_size=32, shuffle=False)
15
16 X, y = next(iter(train_loader))
17 X = X.numpy()
18 y = y.numpy()
19
20 plt.figure(figsize=(6, 7))
21 for i in range(25):
22     plt.subplot(5, 5, i+1)
23     plt.imshow(X[i].reshape(28, 28), cmap=plt.cm.Greys_r)
24     plt.title(y[i])
25     plt.axis('off')

```

Листинг 2: Функция train для нейросети

```

1
2 from tqdm import tqdm
3 def train(network, train_loader, test_loader, epochs, learning_rate,
4           plot=True,
5           verbose=True, loss=None, optimizer='GD'):
6     loss = loss or MSELoss()
7     train_loss_epochs = []
8     test_loss_epochs = []
9     train_accuracy_epochs = []
10    test_accuracy_epochs = []
11    grad_pre = None
12    b = 0
13    try:
14        for epoch in tqdm(range(epochs)):
15            losses = []
16            accuracies = []
17            for X, y in train_loader:
18                X = X.view(X.shape[0], -1).numpy()
19                y = y.numpy()
20                prediction = network.forward(X)
21                loss_batch = loss.forward(prediction, y)
22                losses.append(loss_batch)
23                dLdx = loss.backward()
24
25                if optimizer=='GD':
26                    dLdx = dLdx
27                elif optimizer=='FR':
28                    if grad_pre is None:
29                        grad_pre = dLdx

```

```

29         else :
30             dLdx_flat = dLdx.flatten()
31             grad_pre_flat = grad_pre.flatten()
32             b = (np.sum(dLdx_flat*dLdx_flat)/np.sum(
grad_pre_flat*grad_pre_flat))*2
33             b = max(min(b, 1), 0)
34             grad_pre = dLdx
35             dLdx = (dLdx + b*grad_pre)
36
37         network.backward(dLdx)
38         network.step(learning_rate)
39         accuracies.append((np.argmax(prediction, 1)==y).mean()
)
40     train_loss_epochs.append(np.mean(losses))
41     train_accuracy_epochs.append(np.mean(accuracies))
42     losses = []
43     accuracies = []
44     for X, y in test_loader:
45         X = X.view(X.shape[0], -1).numpy()
46         y = y.numpy()
47         prediction = network.forward(X)
48         loss_batch = loss.forward(prediction, y)
49         losses.append(loss_batch)
50         accuracies.append((np.argmax(prediction, 1)==y).mean()
)
51     test_loss_epochs.append(np.mean(losses))
52     test_accuracy_epochs.append(np.mean(accuracies))
53     clear_output(True)
54     if verbose:
55         sys.stdout.write('\rEpoch {0}... (Train/Test) Loss:
{1:.3f}/{2:.3f}\tAccuracy: {3:.3f}/{4:.3f}'.format(
56             epoch, train_loss_epochs[-1],
test_loss_epochs[-1],
57             train_accuracy_epochs[-1],
test_accuracy_epochs[-1]))
58     if plot:
59         plt.figure(figsize=(12, 5))
60         plt.subplot(1, 2, 1)
61         plt.plot(train_loss_epochs, label='Train')
62         plt.plot(test_loss_epochs, label='Test')
63         plt.xlabel('Epochs', fontsize=16)
64         plt.ylabel('Loss', fontsize=16)
65         plt.legend(loc=0, fontsize=16)
66         plt.grid('on')
67         plt.subplot(1, 2, 2)

```

```

68         plt.plot(train_accuracy_epochs, label='Train accuracy
        ')
69         plt.plot(test_accuracy_epochs, label='Test accuracy')
70         plt.xlabel('Epochs', fontsize=16)
71         plt.ylabel('Accuracy', fontsize=16)
72         plt.legend(loc=0, fontsize=16)
73         plt.grid('on')
74         plt.show()
75     except KeyboardInterrupt:
76         pass
77     return train_loss_epochs, \
78           test_loss_epochs, \
79           train_accuracy_epochs, \
80           test_accuracy_epochs
81
82

```

Листинг 3: Функции активации

```

1
2 class ReLU:
3     def __init__(self):
4         pass
5
6     def forward(self, X):
7         self.X = X
8         return np.maximum(X, 0)
9
10    def backward(self, dLdy):
11        return (self.X > 0) * dLdy
12
13    def step(self, learning_rate):
14        pass
15
16    def softmax(z):
17        exp = np.exp(z - np.max(z))
18
19        for i in range(len(z)):
20            exp[i] /= np.sum(exp[i])
21
22        return exp
23
24    class Softmax:
25        def __init__(self):
26            pass
27
28        def forward(self, inputs):

```

```

29         self.inputs = inputs
30         return softmax(inputs)
31
32     def backward(self, dLdy):
33         return dLdy
34
35     def step(self, learning_rate):
36         pass
37
38

```

Листинг 4: Лосс функции

```

1
2 class CELoss:
3     def __init__(self):
4         pass
5
6     def forward(self, X, y):
7         self.p = np.exp(X - np.max(X, axis=1, keepdims=True))
8         self.p /= self.p.sum(axis=1, keepdims=True)
9
10        self.y = np.zeros((X.shape[0], X.shape[1]))
11        self.y[np.arange(X.shape[0]), y] = 1
12
13        return -np.mean(np.sum(self.y * np.log(self.p + 1e-15), axis=1))
14
15    def backward(self):
16        return (self.p - self.y) / self.y.shape[0]
17
18 class MSELoss:
19     def __init__(self):
20         pass
21
22    def forward(self, X, y):
23        self.X = X
24
25        self.y = np.zeros((X.shape[0], X.shape[1]))
26        self.y[np.arange(X.shape[0]), y] = 1
27
28        return np.mean(np.square(self.X - self.y))
29
30    def backward(self):
31        return 2 * (self.X - self.y) / self.y.shape[0]
32
33
34 class KLLoss:

```

```

35     def __init__(self):
36         pass
37
38     def forward(self, pred, target):
39         self.pred = np.clip(pred, 1e-10, 1 - 1e-10)
40
41         self.target = np.zeros((pred.shape[0], pred.shape[1]))
42         self.target[np.arange(pred.shape[0]), target] = 1
43
44         self.target = np.clip(self.target, 1e-10, 1 - 1e-10)
45
46         return np.mean(self.target * np.log(self.target/self.pred))
47
48     def backward(self):
49         self.pred = np.clip(self.pred, 1e-8, 1 - 1e-8)
50         res = self.pred - self.target
51         return res / np.linalg.norm(res)
52
53

```

Листинг 5: Структура Нейронной сети

```

1
2     class Linear:
3     def __init__(self, input_size, output_size):
4         self.W = np.random.randn(input_size, output_size)*0.01
5         self.b = np.zeros(output_size)
6
7     def forward(self, X):
8         self.X = X
9         return X.dot(self.W)+self.b
10
11    def backward(self, dLdy):
12        self.dLdW = self.X.T.dot(dLdy)
13        self.dLdb = dLdy.sum(0)
14        self.dLdx = dLdy.dot(self.W.T)
15        return self.dLdx
16
17    def step(self, learning_rate):
18        self.W = self.W - learning_rate * self.dLdW
19        self.b = self.b - learning_rate * self.dLdb
20
21
22    class NeuralNetwork:
23    def __init__(self, modules):
24        self.modules = modules
25

```

```
26     def forward(self , X):
27         y = X
28         for i in range(len(self.modules)):
29             y = self.modules[i].forward(y)
30         return y
31
32     def backward(self , dLdy):
33         for i in range(len(self.modules))[::-1]:
34             dLdy = self.modules[i].backward(dLdy)
35
36     def step(self , learning_rate):
37         for i in range(len(self.modules)):
38             self.modules[i].step(learning_rate)
39
40
```


4 Результаты

Результаты представлено на рисунках 1 - 2.

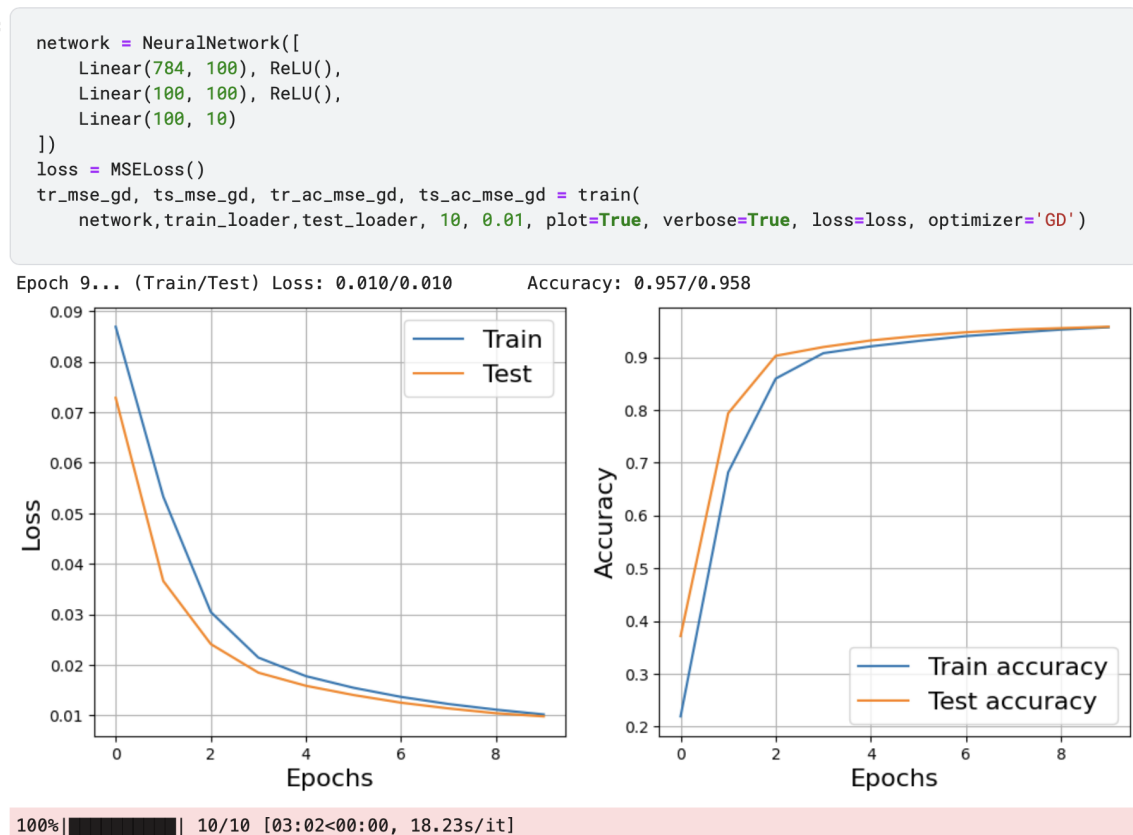


Рис. 1 — Графики для MSE Loss + GD

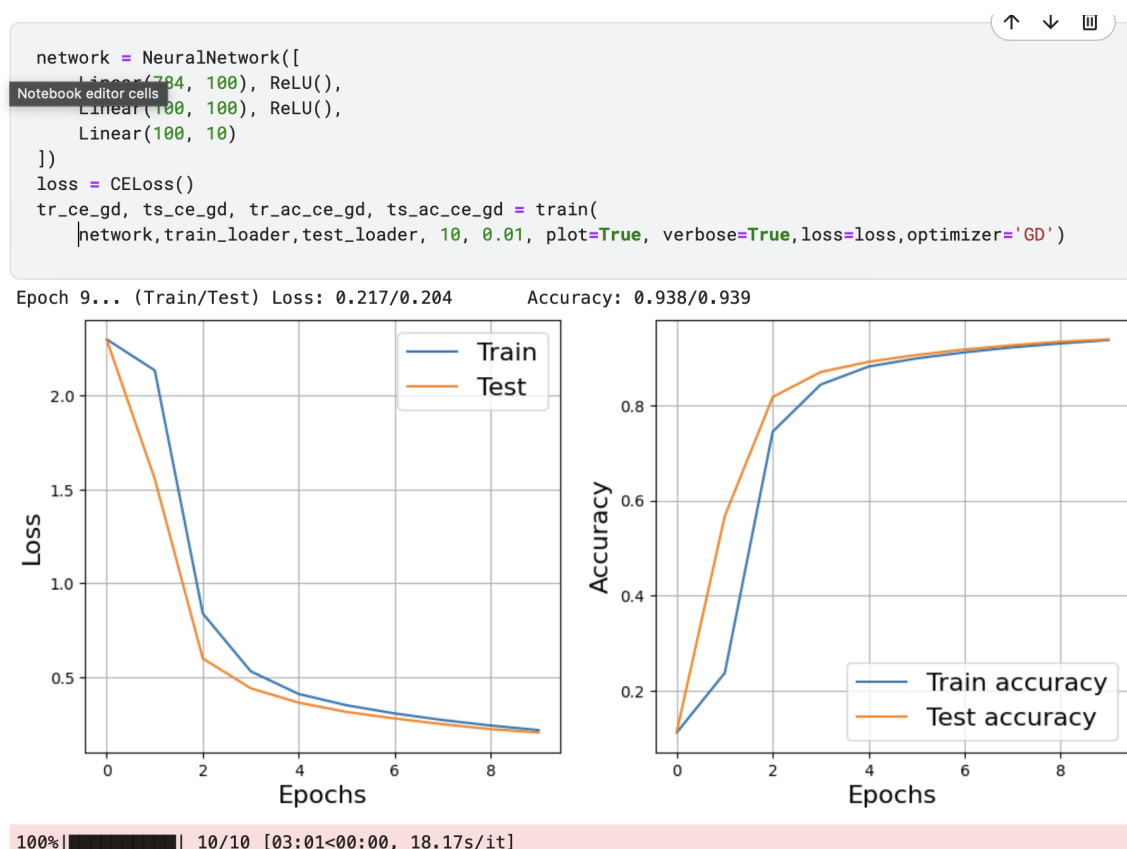


Рис. 2 — Графики для CE Loss + GD

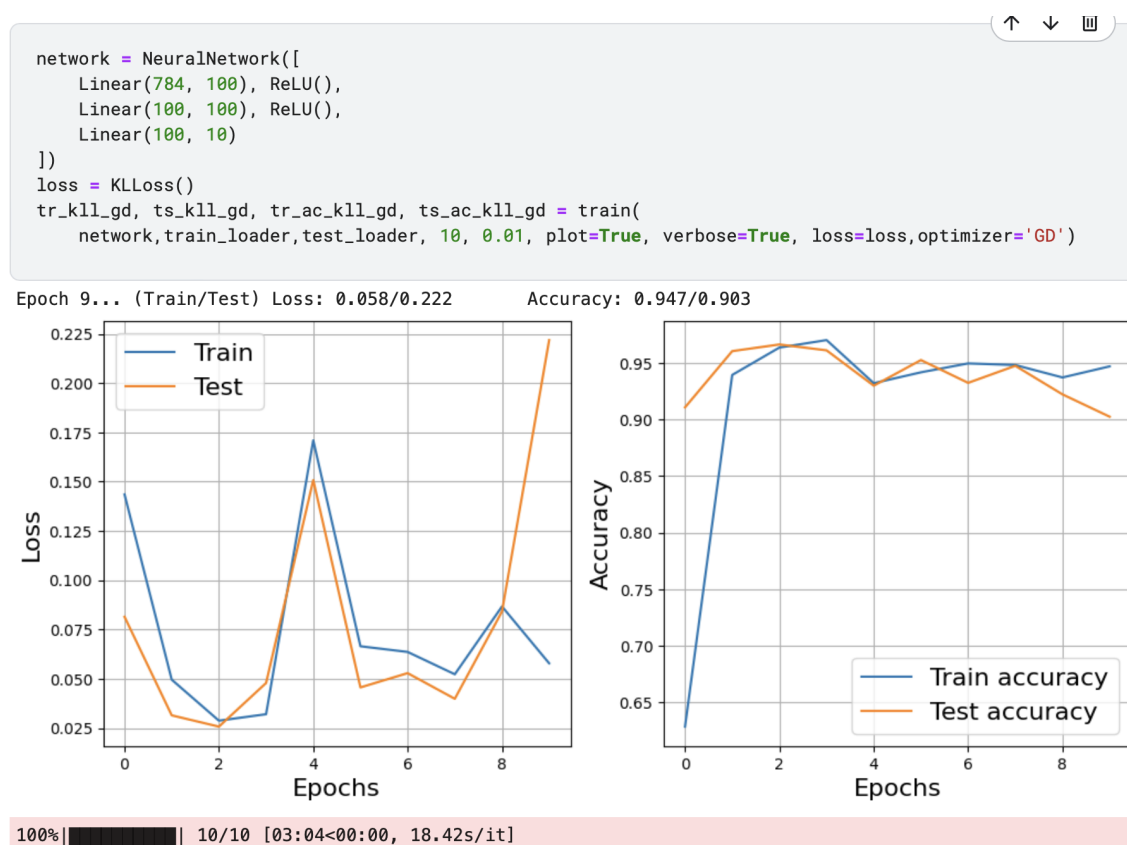


Рис. 3 — Графики для KLL Loss + GD

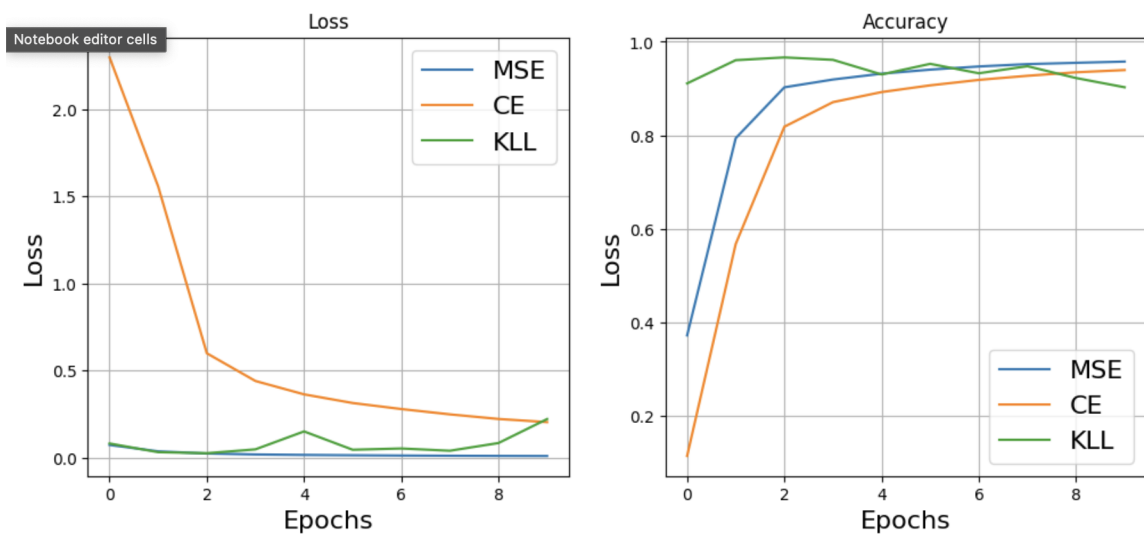


Рис. 4 — Графики сравнения MSE, CE, KLL

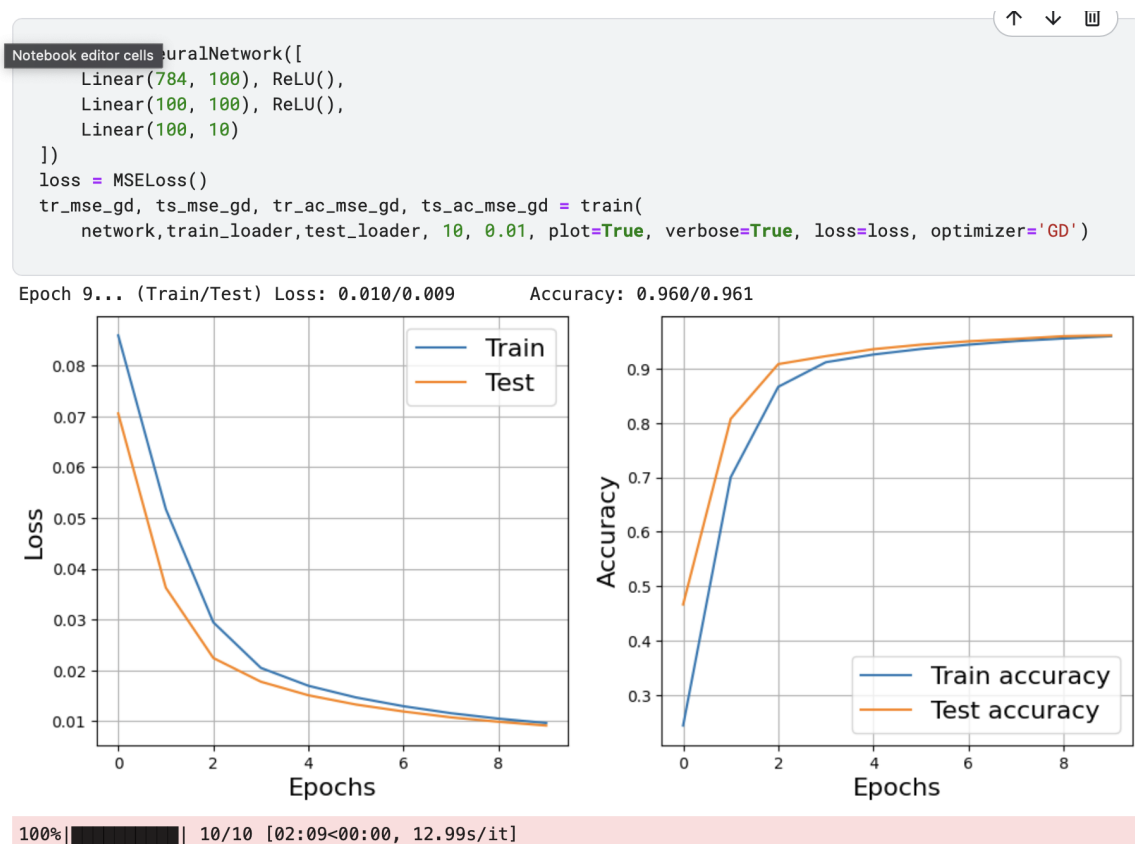


Рис. 5 — Графики для MSE Loss + GD

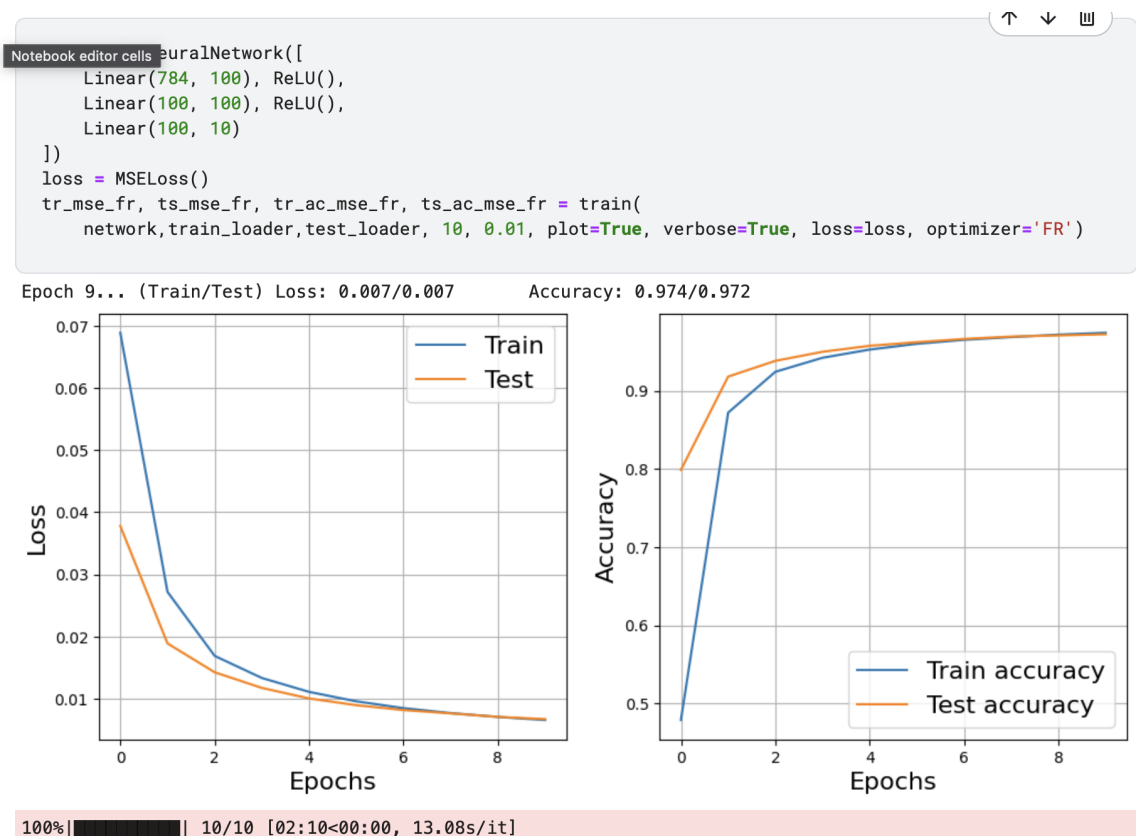


Рис. 6 — Графики для MSE Loss + FR




Рис. 7 — Графики сравнения GD и FR

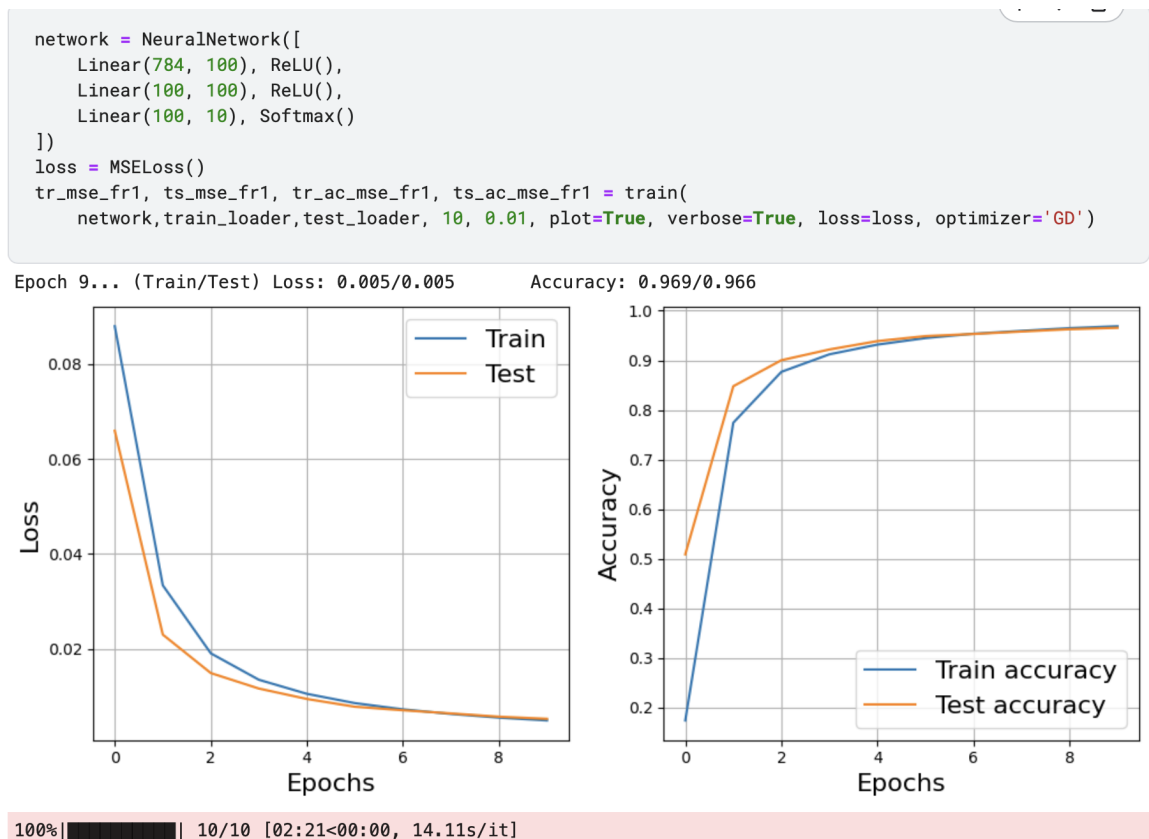


Рис. 8 — Добавление Softmax




Рис. 9 — Добавление скрытого слоя

5 Выводы

В результате данной лабораторной работы был изучен метод построения архитектуры многослойного персептрона. Были проведены эксперименты с количеством скрытых слоев и размерностью входа/выхода слоя, в результате которых была выбрана архитектура, на которой проводились все дальнейшие действия. 1) Было проведено сравнение различных функций потерь, где наглядно было видно, что, используя KLL Loss нейронная сеть обучается за 3 эпохи, а потом происходит переобучение, остальные функции потерь показали примерно одинаковые результаты. 2) Далее было проведено исследование различных методов оптимизации, для этого была зафиксирована функция потерь, и проведены эксперименты, при которых метод сопряженных градиентов показал себя ожидаемо лучше обычного градиентного спуска. В результате можно сказать, что очень важно подобрать правильное количество скрытых слоёв модели и их размерность, а также функцию потерь, а уже потом можно экспериментировать с различными оптимизациями.